

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH
TEHNOLOGIJA

Aproksimiranje kontinuirane funkcije neuronskom mrežom

Meko računarstvo

Laboratorijska vježba 4

Aleksandra Kuridža

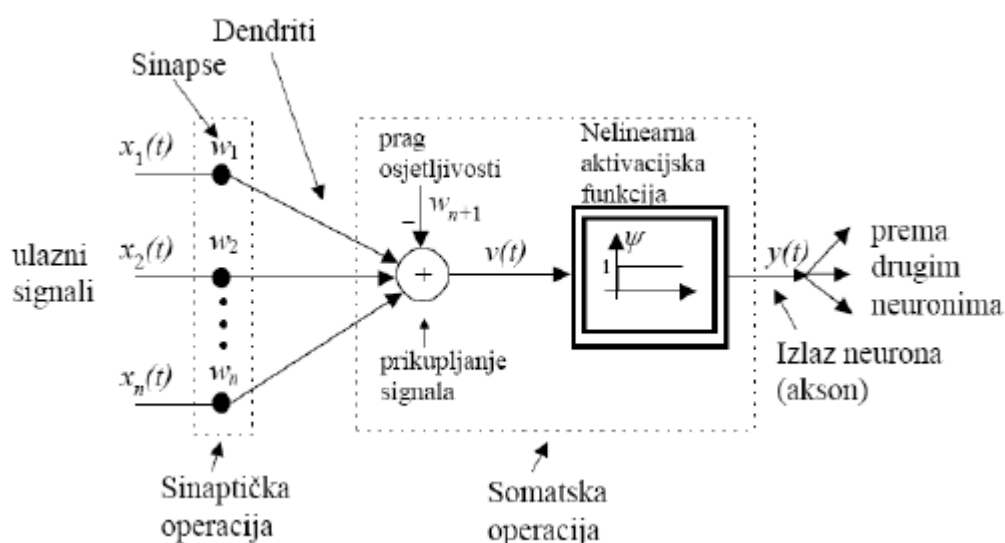
Diplomski studij računarstva, DRB

1. UVOD

Cilj četvrte laboratorijske vježbe bio je projektirati i ispitati neuronsku mrežu za aproksimaciju funkcije koja je navedena u poglavlju 3, na temelju ulaznih i izlaznih veličina. Bilo je potrebno prikazati kako struktura mreže, prijenosna funkcija neurona u skrivenom sloju, algoritam za učenje i broj uzoraka za učenje utječu na dobivene rezultate.

2. NEURONSKE MREŽE

Neuronske mreže su sustavi za procesuiranje informacija koji su inspirirani biološkim živčanim sustavom kao što je mozak. Sastoji se od velikog broja međusobno povezanih procesnih elemenata tzv. neurona. Svaki neuron je sumirajući element povezan sa aktivacijskom funkcijom. Prvi model neurona koji je bio osmišljen još 1943. od strane McCullocha i Pittsa se zvao „perceptron“ i njegova jedina razlika od modernijih modela neurona je bila ta što je kao prijenosnu funkciju koristio diskontinuiranu step funkciju. Kasnije su se počee koristiti kontinuirane funkcije. Najveća revolucija se dogodila uvođenjem višeslojnih mreža i njihovih algoritama za učenje.



Slika 2.1. Shematski prikaz perceptrona

Iz slike 2 je vidljivo kako svaki neuron prikuplja signale od prethodnog sloja (pomnožene sa težinama), te uz dodatak praga osjetljivosti dolazi do prijenosne funkcije odnosno nelinearne aktivacijske funkcije. Izlaz iz te funkcije potom odlazi do svakog neurona u idućem sloju gdje se proces ponavlja. Neuroni se najčešće dijele na statičke i dinamičke, gdje statički neuroni ovise isključivo o trenutnim vrijednostima signala i težina, dok kod dinamičkih postoje određene povratne veze i promjenjive aktivacijske funkcije.

Da bi se neuronska mreža definirala, pored osnovnih parametara koji opisuju oblik i tip mreže, odnosno arhitekturu, potrebno je odrediti i algoritam učenja.

Proces učenja je u biti proces optimizacije pomoću algoritma gdje se pronalaze težine između neurona koje najbolje opisuju rješenje odnosno aproksimaciju problema. Proces učenja najčešće uključuje slijedeće korake:

- Dovođenje na ulaz neuronske mreže niz slučajeva (uzoraka) koje želimo naučiti raspoznavati.
- Odrediti pogrešku između dobivenog izlaza i željenog izlaza.
- Promijeniti težine da bi se izlaz bolje aproksimirao

Imamo 3 osnovna tipa učenja neuronskih mreža:

- Nadzirano učenje – učenje na temelju poznatih uzoraka i rezultata
- Učenje pojačavanjem – uključuje povratnu vezu iz okoline
- Nenadzirano učenje – učenje iz pravilnosti ulaznih podataka.

Najčešće se koristi nadzirano učenje, a najčešće korišteni algoritam učenja je sa povratnom propagacijom pogreške (eng. backpropagation).

Neuronske mreže zbog svoje sposobnosti učenja i aproksimacije se najčešće koristi za slijedeće primjene:

- Raspoznavanje znakova teksta (i analiza slike),
- Prepoznavanje govora,
- Adaptivno uklanjanje šuma,
- Predviđanje cijena dionica(financije),
- Medicinska dijagnostika.

3. ZADATAK I REZULTATI

Parametre zadatka mijenjati na slijedeće vrijednosti:

- Broj uzoraka funkcije : 10, 30, 60
- Broj neurona u skrivenom sloju: 5, 10, 30
- Prijenosna funkcija skrivenog sloja: Bipolar Sigmoid, Sigmoid, Linear, Rectified Linear.
- Algoritam učenja: Levenberg Marquardt, Backpropagation, Resilient Backpropagation Learning, Evolutionary.

Rješenje je potrebno izraditi i pokazati u terminu laboratorijskih vježbi, te na idućim vježbama predati kao pisano izvješće koje treba sadržavati:

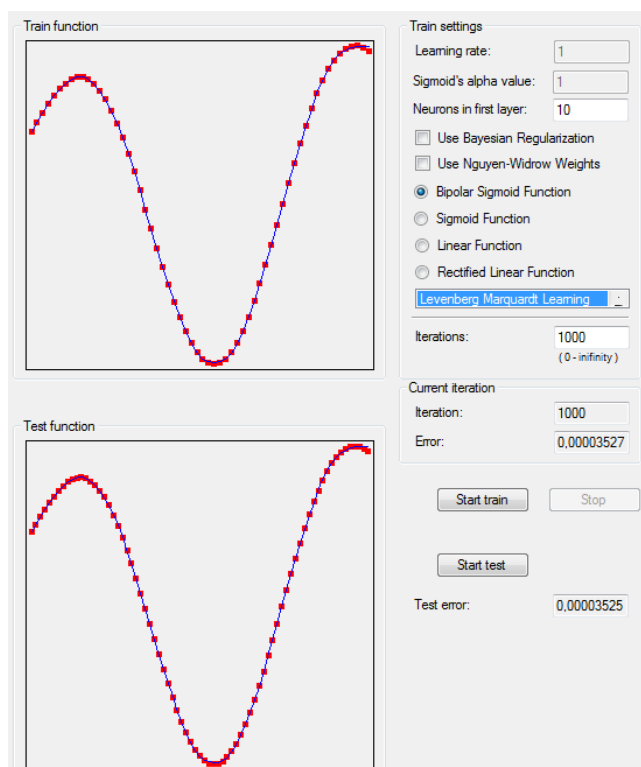
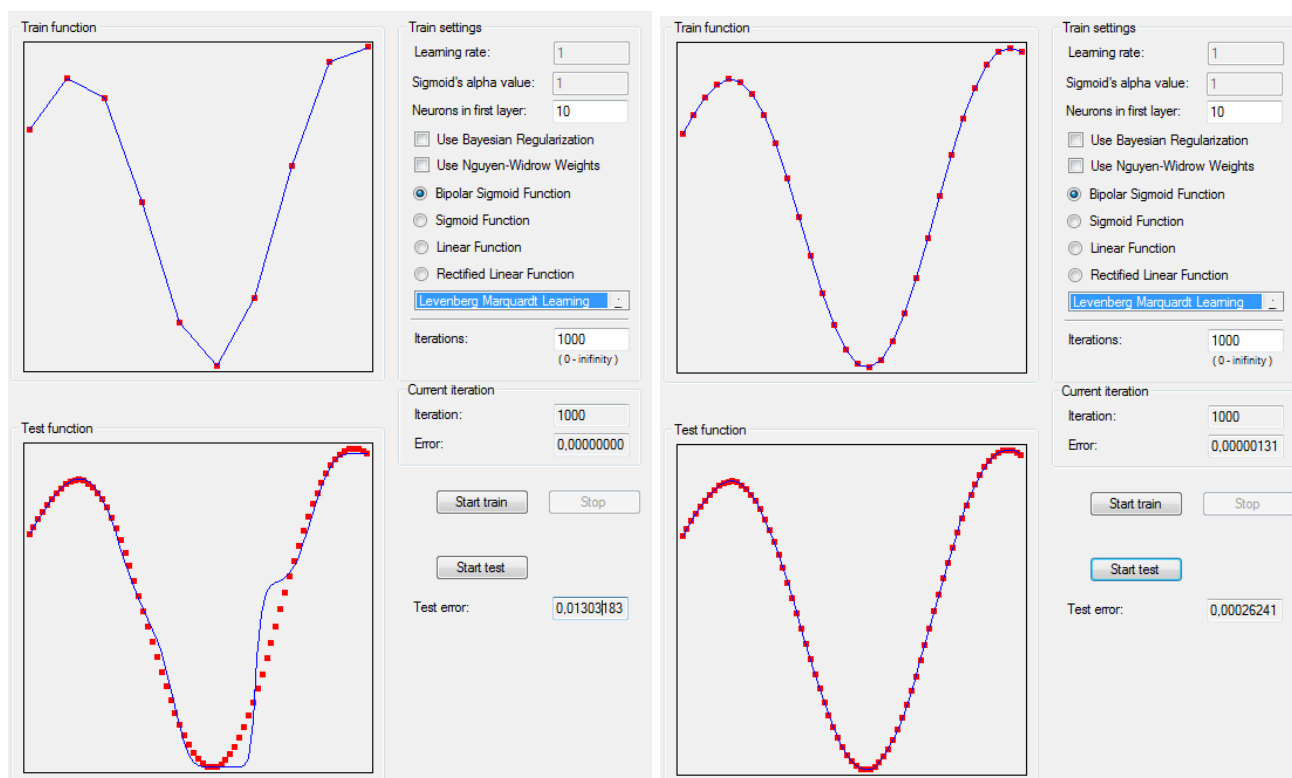
- opis problema, razlozi za korištenje neuronske mreže,
- utjecaj strukture mreže (broja neurona u skrivenom sloju).
- utjecaj prijenosne funkcije neurona u skrivenom sloju
- utjecaj algoritma za učenje
- utjecaj broja uzoraka za učenje
- dobivena rješenja prikazati grafički, tablično i obrazložiti.

3.1. UTJECAJ BROJA UZORAKA FUNKCIJE

Broj iteracija: 1000 za sva mjerenja

Broj neurona u skrivenom sloju	10		
Prijenosna funkcija skrivenog sloja	Bipolar Sigmoid		
Algoritam učenja	Levenberg Marquardt		
Broj uzoraka funkcije	10	30	60
Error	0	0,00000131	0,00003527
Test error	0,01303183	0,00026241	0,00003525

Tablica 3.1.1. Ovisnost o broju uzoraka funkcije

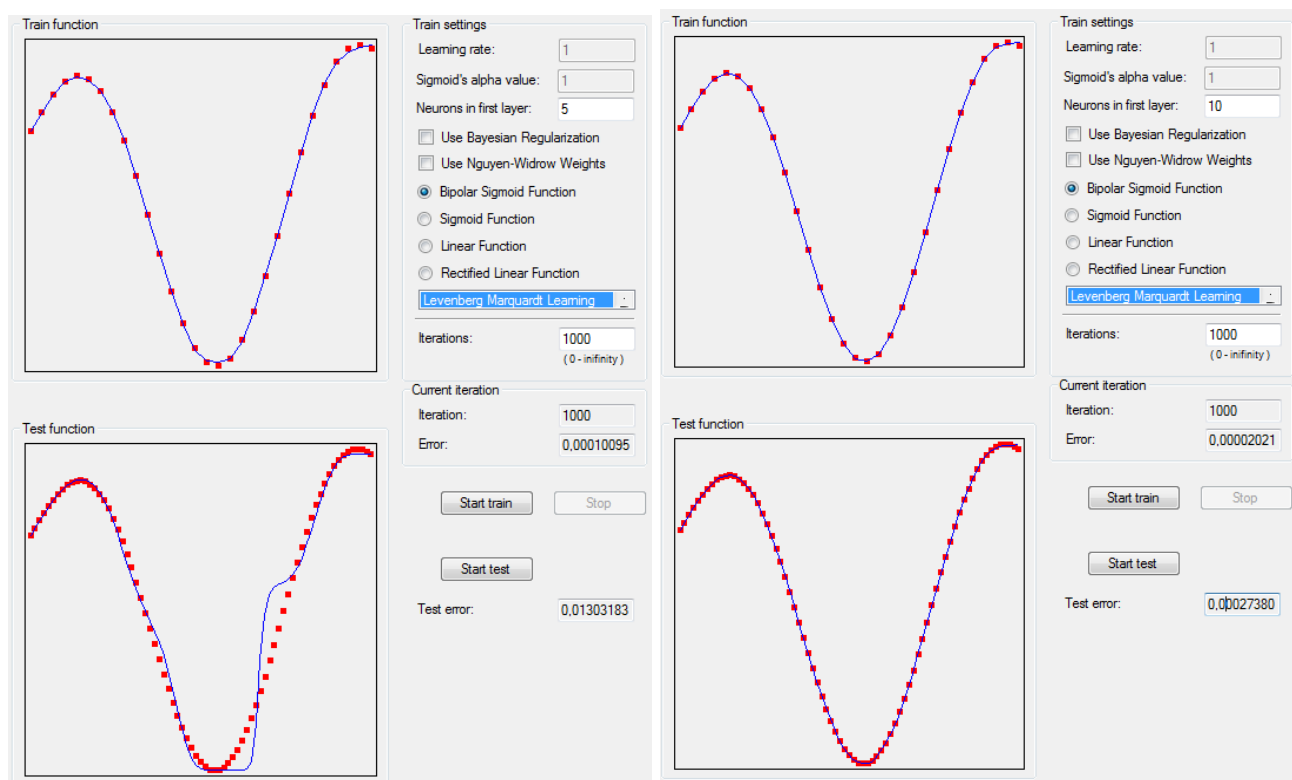


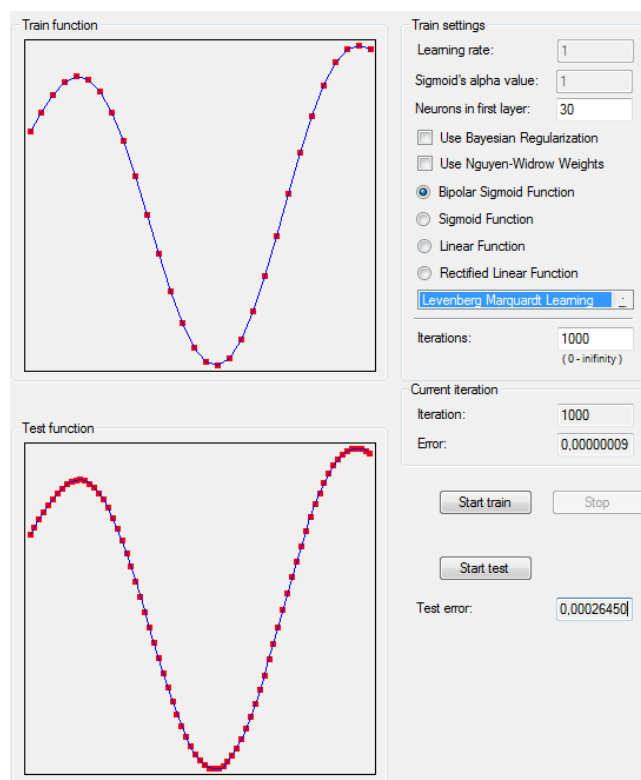
Slika 3.1.1. Ovisnost o broju uzoraka funkcije

3.2. UTJECAJ BROJA NEURONA U SKRIVENOM SLOJU

Broj uzoraka funkcije	30		
Prijenosna funkcija skrivenog sloja	Bipolar Sigmoid		
Algoritam učenja	Levenberg Marquardt		
Broj neurona u skrivenom sloju	5	10	30
Error	0,00010095	0,00002021	0,00000009
Test error	0,01303183	0,00027380	0,00026450

Tablica 3.2.1. Ovisnost o broju neurona u skrivenom sloju



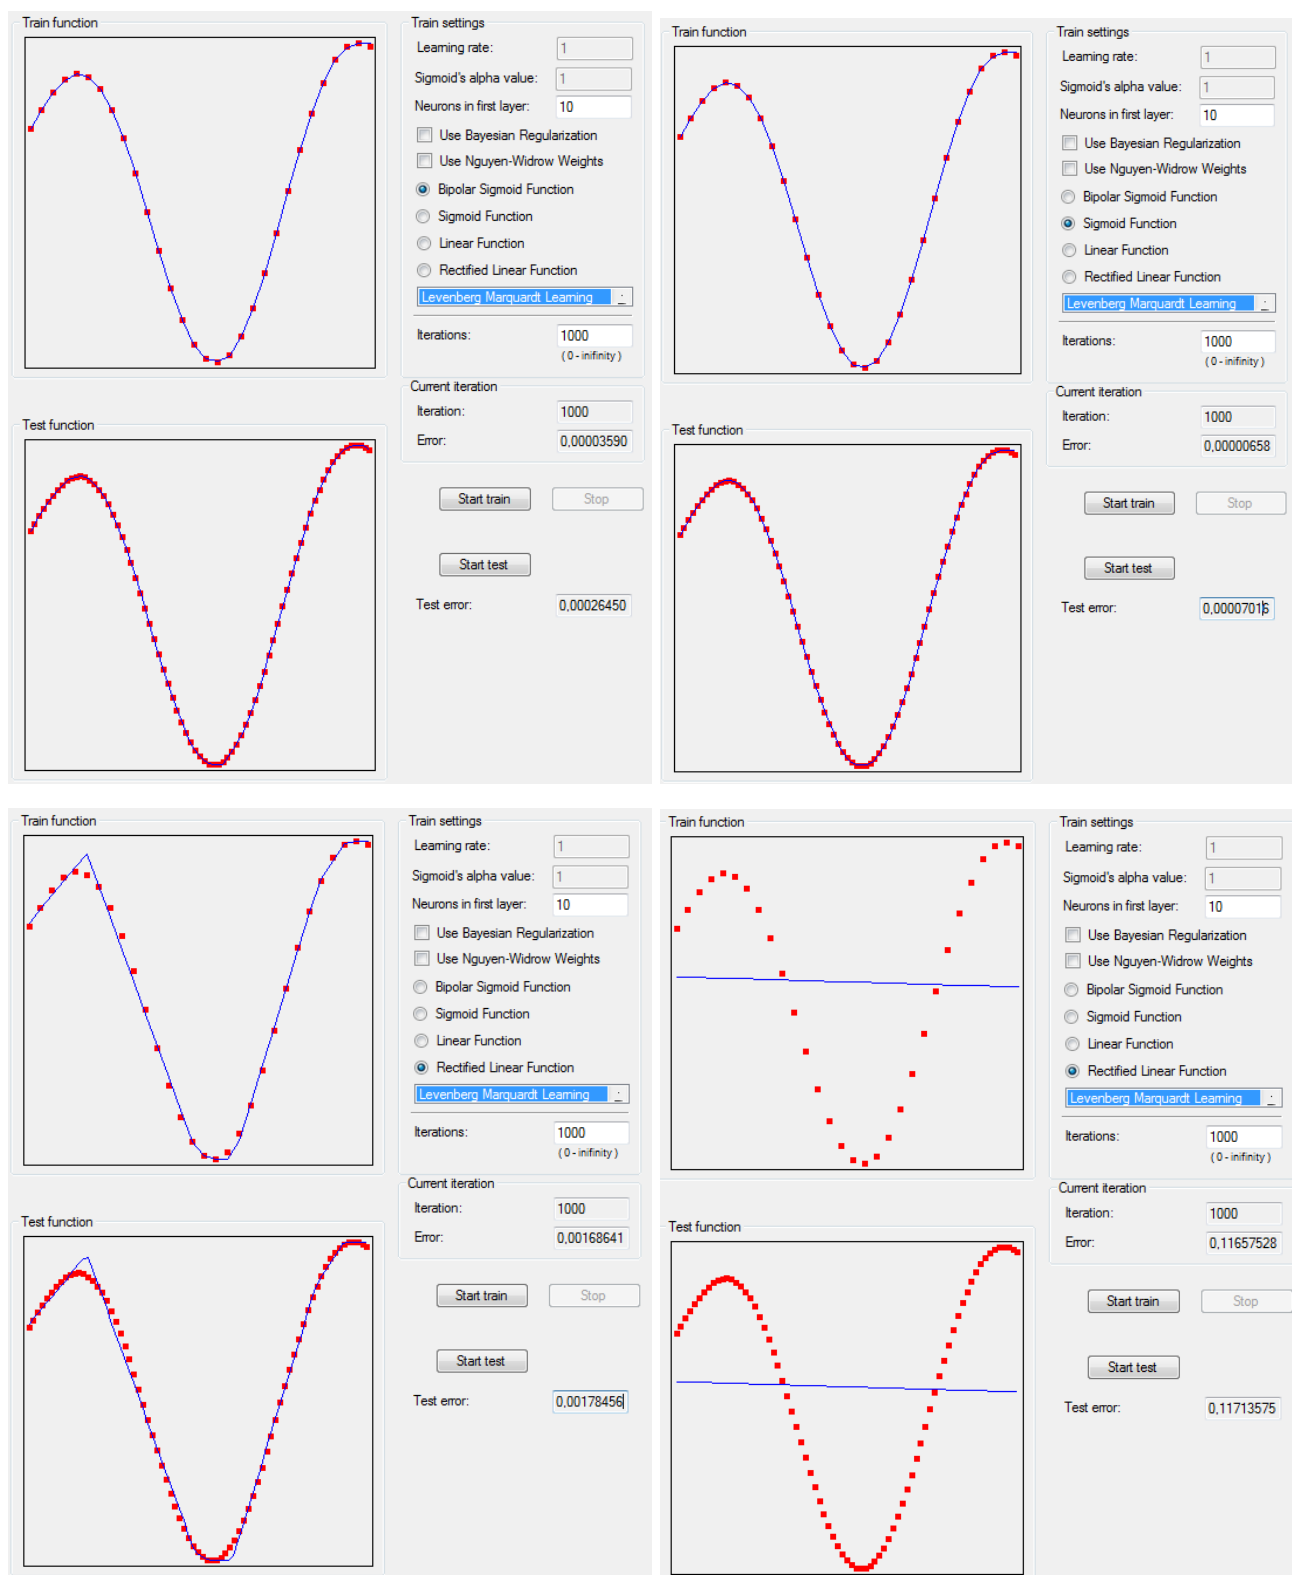


Slika 3.2.1. Ovisnost o broju neurona u skrivenom sloju

3.3. UTJECAJ PRIJENOSNE FUNKCIJE SKRIVENOG SLOJA

Broj uzoraka funkcije	30			
Broj neurona u skrivenom sloju	10			
Algoritam učenja	Levenberg Marquardt			
Prijenosna funkcija skrivenog sloja	Bipolar Sigmoid	Sigmoid	Linear	Rectified Linear
Error	0,00003590	0,00000658	0,00168641	0,11657528
Test error	0,00026450	0,00007016	0,00178456	0,11713575

Tablica 3.3.1. Ovisnost o prijenosnoj funkciji skrivenog sloja

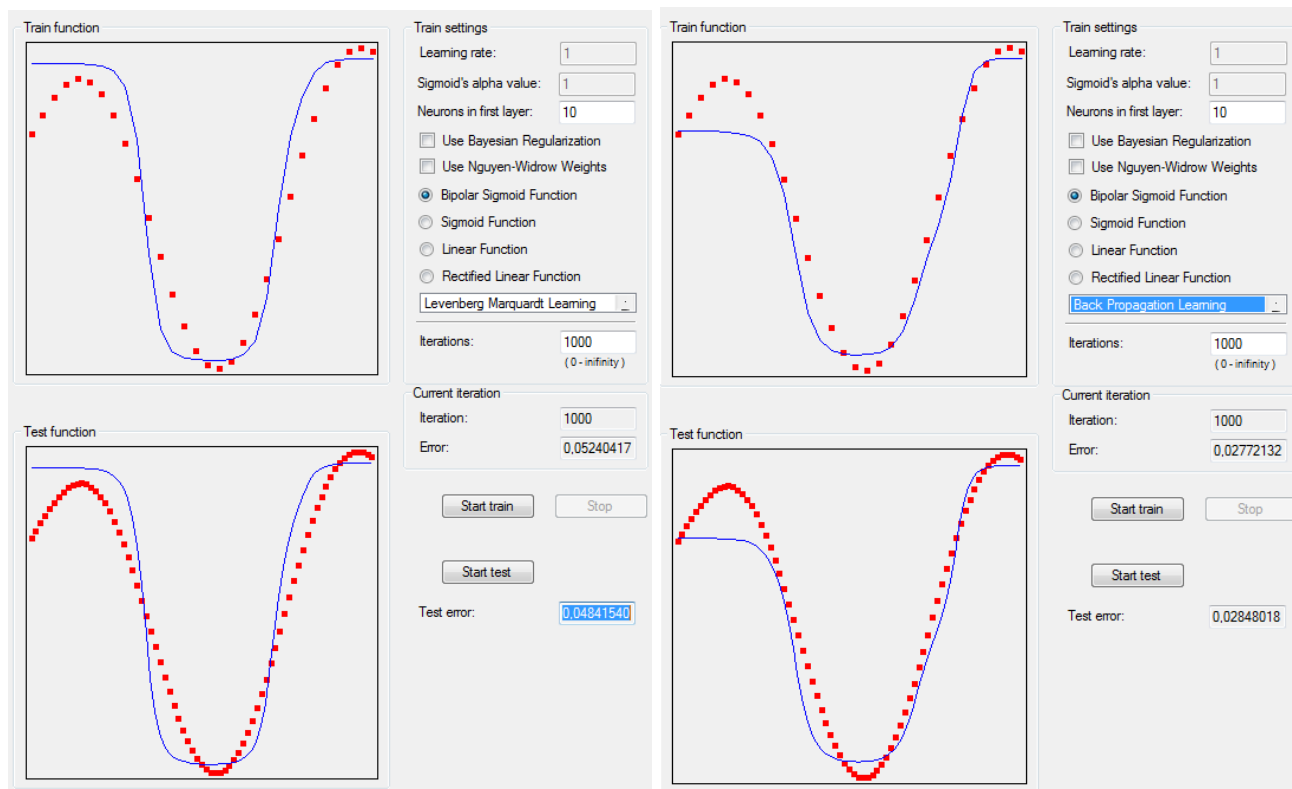


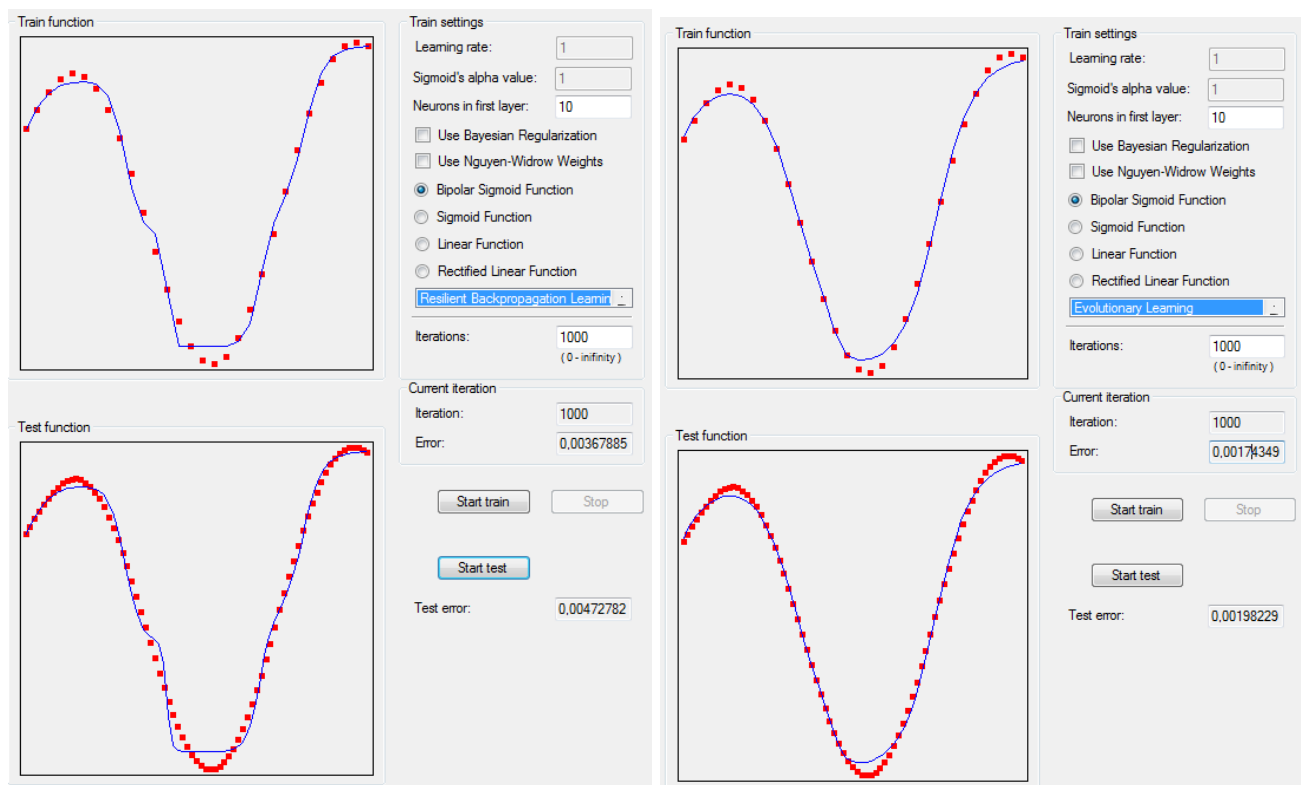
Slika 3.3.1. Ovisnost o prijenosnoj funkciji skrivenog sloja

3.4. UTJECAJ ALGORITMA UČENJA

Broj uzoraka funkcije	30			
Broj neurona u skrivenom sloju	10			
Prijenosna funkcija skrivenog sloja	Bipolar Sigmoid			
Algoritam učenja	Levenberg Marquardt	Backpropagation	Resilient Backpropagation Learning	Evolutionary
Error	0,05240417	0,02772132	0,00367885	0,00174349
Test error	0,04841540	0,02848018	0,00472782	0,00198229

Tablica 3.4.1. Ovisnost o algoritmu učenja





Slika 3.4.1. Ovisnost o algoritmu učenja

4. ZAKLJUČAK

Kod testiranja utjecaja broja uzoraka funkcije fiksirali smo broj neurona u skriveno sloju na 10. Uzeli smo Bipolar Sigmoid prijenosnu funkciju i Levenberg Marquardt algoritam učenja. Mjenjali smo broj uzoraka funkcije na 10, 30 i 60. **Najbolje** rješenje dobili smo za **60 uzoraka funkcije, a najgore za 10.**

Kod testiranja utjecaja neurona u skrivenom sloju fiksirali smo broj uzoraka funkcije na 30. Korištena je Bipolar Sigmoid prijenosna funkcija i Levenberg Marquardt algoritam učenja. Mjenjali smo broj neuronu u skrivenom sloju na 5, 10 i 30. **Najbolje** rješenje dobiveno je za **30 neurona u skrivenom sloju**, dok je **najgore** dobiveno za **5 neurona** u skrivenom sloju.

Kod testiranja utjecaja prijenosne funkcije skrivenog sloja korištene su Bipolar Sigmoid, Sigmoid, Linear i Rectified Linear funkcije. Broj uzoraka funkcije fiksirali smo a 30, broj neurona u skrivenom sloju na 10 i korišten je Levenberg Marquardt algoritam učenja. Prijenosna funkcija skrivenog sloja koja daje **najbolji** rezultat je „**Bipolar Sigmoid**“, zatim „Sigmoid“, nakon toga „Linear“, a **najgori** rezultat daje funkcija „**Rectified Linear**“.

Zadnje testiranje koje je izvršeno bilo je utjecaj algoritma učenja. Fiksirali smo broj neurona u skrivenom sloju na 10. Uzeli smo Bipolar Sigmoid prijenosnu funkciju te broj uzoraka funkcije 30. **Najbolji** rezultat je ostvaren korištenjem **Evolutionary** algoritma. Sljedeći najbolji rezultat dobiven je Resilient Backpropagation Learning algoritmom. **Najlošija** rješenja dobivena su Backpropagation i **Levenberg Marquardt** algoritmima.

Datoteke s 10, 30 i 60 uzoraka koristili smo za učenje neuronskih mreža dok smo onu sa 75 uzoraka koristiti za testiranje.