

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA

Klasificiranje vrste svijeta Irida pomoću neuronskih mreža

Meko računarstvo

Laboratorijska vježba 5

Ivan Gudelj

Diplomski studij računarstva, DRB

Osijek, 2022.

UVOD	3
OPIS PROBLEMA I RJEŠENJA	4
Neuronske mreže	4
REZULTATI ZA TRAŽENI PROBLEM - KLASIFICIRANJE CVIJETA	6
Utjecaj strukture mreže (broja neurona u skrivenom sloju)	6
Utjecaj aktivacijske funkcije neurona u skrivenom sloju	11
Utjecaj algoritma za učenje neuronske mreže	13
ZAKLJUČAK	15

1. UVOD

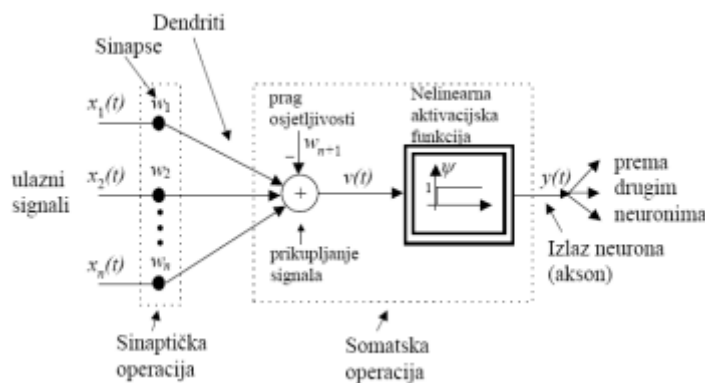
Cilj pete laboratorijske vježbe je bio projektirati i ispitati neuronsku mrežu koja određuje vrstu cvijeta Iris-a (perunike) na osnovu mjernih karakteristika istog. Na raspolaganju smo imali bazu podataka s 25 uzoraka za svaku vrstu cvijeta za treniranje neuronske mreže te 25 uzoraka svakog cvijeta za testiranje navedene neuronske mreže. Mjerene veličine cvijeta uključuju dužine i širine latica i čašićnih listića, pored te četiri fizičke mjere svaki uzorak je još definiran svojom vrstom (0, 1 ili 2). Postoje tri vrste cvjetova Irida; *SETOSA*, *VIRGINICA* te *VERSICOLOR*. Zadatak je bio prikazati kako aktivacijska funkcija, broj neurona u skrivenom sloju te algoritam za učenje utječu na dobivene rezultate.

2. OPIS PROBLEMA I RJEŠENJA

2.1. Neuronske mreže

Neuronske mreže su sustavi za procesuiranje informacija koji su inspirirani biološkim živčanim sustavom kao što je mozak. Sastoji se od uvjetno rečeno velikog broja međusobno povezanih procesnih elemenata tzv. neurona. Svaki neuron je u biti sumirajući element povezan sa aktivacijskom funkcijom. Biološki neuroni primaju elektrokemijske pobude preko dendrita, a ako je težinska suma svih ulaza na dendritima veća od praga, neuron okida i šalje impuls na aksion preko kojeg je spojen s ulazima ostalih neurona.


Prvi model neurona koji je bio osmišljen još 1943. od strane McCullocha i Pittsa se zvao „perceptron“ i njegova jedina razlika od modernijih modela neurona je bila ta što je kao prijenosnu funkciju koristio diskontinuiranu step funkciju. Dok su se kasnije puno logičnije počele koristiti kontinuirane funkcije, bile one linearne ili sigmoidalne (logsig, tansig). Jer u slučaju kontinuirane funkcije imamo mogućnosti puno preciznije aproksimacije modela problema. Ali je najveća revolucija započela uvođenjem višeslojnih mreža i njihovih algoritama za učenje



$$v(t) = \sum_{i=1}^n w_i(t) \cdot x_i(t) - w_{n+1}, \quad u(t) = \psi(v), \quad y(t) = \mathbf{w}^T(t) \cdot \mathbf{x}(t)$$

Kao što se vidi na slici iznad, svaki neuron prikuplja signale od prethodnog sloja (pomnožene sa težinama), te uz dodatak praga osjetljivosti dolazi do prijenosne funkcije odnosno nelinearne aktivacijske funkcije. Izlaz iz te funkcije potom odlazi do svakog neurona u idućem sloju gdje se proces ponavlja. Neuroni se najčešće dijele na statičke i dinamičke,

gdje statički neuroni ovise isključivo o trenutnim vrijednostima signala i težina, dok kod dinamičkih postoje određene povratne veze i promjenjive aktivacijske funkcije. Kao što je ranije rečeno aktivacijske funkcije najčešće su sigmoide kao što vidimo na slijedećim slikama.



Da bi se neuronska mreža definirala, pored osnovnih parametara koji opisuju oblik i tip mreže, odnosno arhitekturu, potrebno je odrediti i algoritam učenja. Proces učenja je u biti proces optimizacije pomoću algoritma gdje se pronalaze težine između neurona koje najbolje opisuju rješenje odnosno aproksimaciju problema. Proces učenja najčešće uključuje sljedeće korake: Dovođenje na ulaz neuronske mreže niz slučajeva (uzoraka) koje želimo naučiti raspoznavati. Odrediti pogrešku između dobivenog izlaza i željenog izlaza. Promijeniti težine da bi se izlaz bolje aproksimirao.

Iako broj neurona nije ograničen do sada se je u praktičnim primjenama koristilo do najviše par stotina neurona i to u jako kompleksnim primjenama. Jer uvođenjem dodatnih neurona (i slojeva) višestruko povećava problem učenja, a može se dogoditi da u slučaju pretjeranog broja neurona (za pojedini problem) može unijeti smetnje u izlaz neuronske mreže zbog neskladnog rada. Imamo 3 osnovna tipa učenja neuronskih mreža: Nadzirano učenje – učenje na temelju poznatih uzoraka i rezultata, Učenje pojačavanjem – uključuje povratnu vezu iz okoline, Nenadzirano učenje – učenje iz pravilnosti ulaznih podataka.

3. REZULTATI ZA TRAŽENI PROBLEM - KLASIFICIRANJE CVIJETA

Parametre zadatka mijenjati na sljedeće vrijednosti:

Broj neurona po skrivenom sloju: **5, 10, 30**.


Broj skrivenih slojeva: **1, 2, 3**.



Aktivacijska funkcija skrivenog sloja: **‘identity’, ‘logistic’, ‘tanh’, ‘relu’**.

Algoritam učenja: **‘lbfgs’, ‘sgd’, ‘adam’**

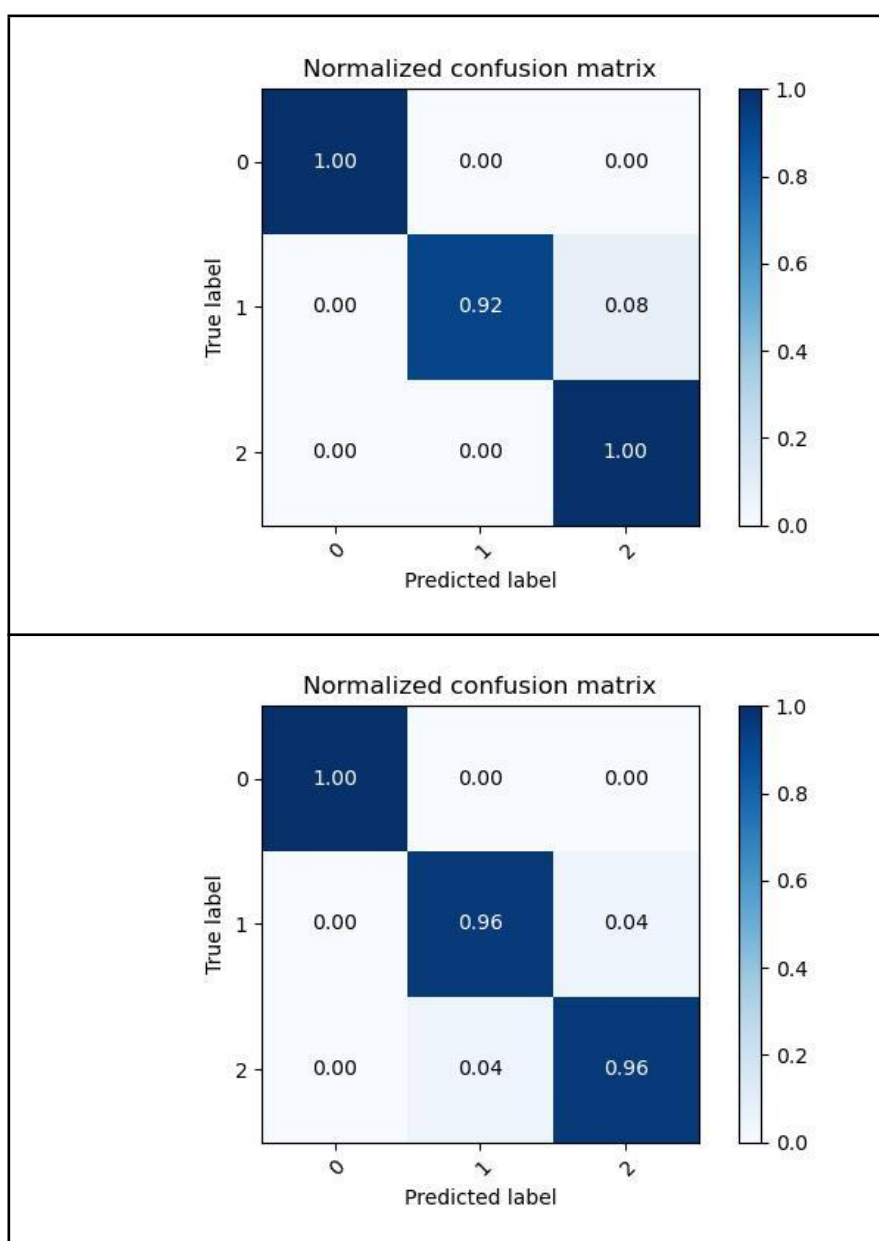
3.1. Utjecaj strukture mreže (broja neurona u skrivenom sloju)


Broj skrivenih slojeva	1		
Aktivacijska funkcija skrivenog sloja	logistic		
Algoritam učenja	adam		
Broj neurona po skrivenom sloju	5	10	30
MSE	0.3075189	0.172492	0.068299






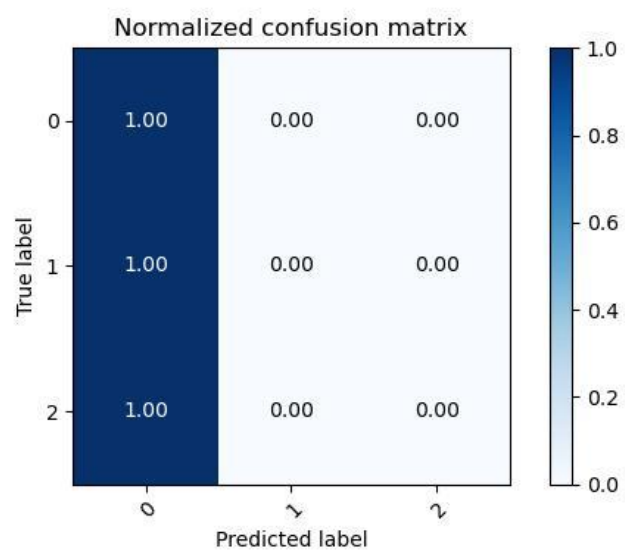

Broj skrivenih slojeva	2		
Aktivacijska funkcija skrivenog sloja	logistic		
Algoritam učenja	adam		
Broj neurona po skrivenom sloju	5	10	30
MSE	0.355887	0.095631	0.039816






Broj skrivenih slojeva	3		
Aktivacijska funkcija skrivenog sloja	logistic		
Algoritam učenja	adam		
Broj neurona po skrivenom sloju	5	10	30
MSE	0.497522	1.097377	0.029473








3.2. Utjecaj aktivacijske funkcije neurona u skrivenom sloju

Broj skrivenih slojeva	2			
Broj neurona po skrivenom sloju	5			
Algoritam učenja	adam			
Aktivacijska funkcija skrivenog sloja	identity	logistic	tanh	relu
MSE	0.061054	0.355886	0.059922	0.051780





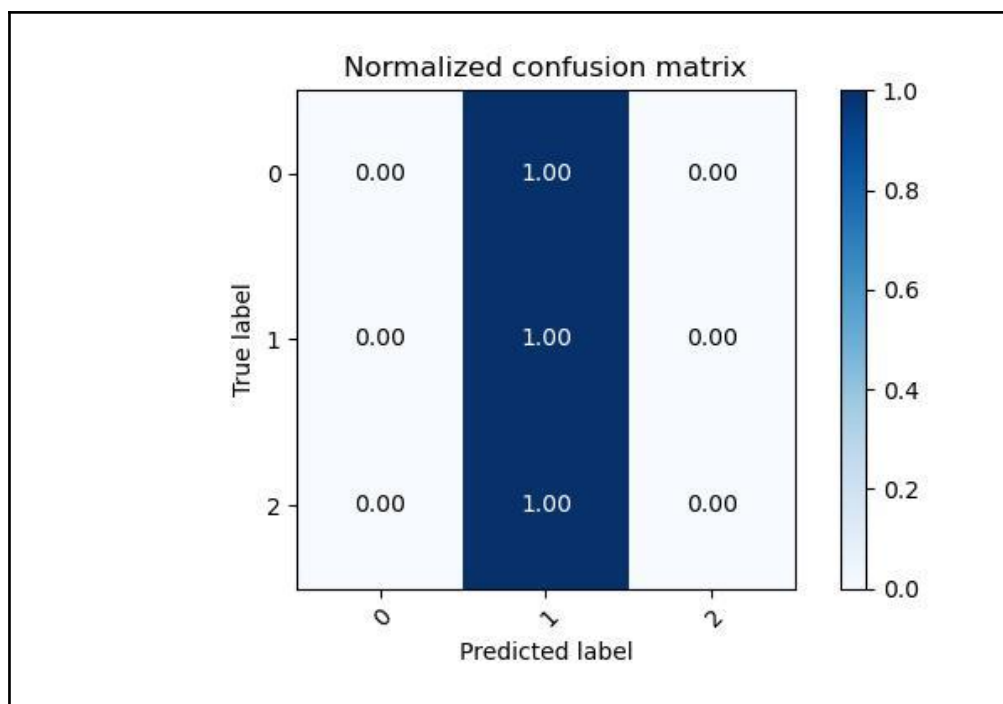




3.3. Utjecaj algoritma za učenje neuronske mreže

Broj skrivenih slojeva	3		
Aktivacijska funkcija skrivenog sloja	logistic		
Broj neurona po skrivenom sloju	10		
Algoritam učenja	lbfgs	sgd	adam
MSE	0.0004186	1.100786	1.097377





4. ZAKLJUČAK

U rezultatima su prikazane ovisnosti o algoritmu za učenje neuronske mreže, ovisnosti o aktivacijskoj funkciji neuronske mreže, ovisnost o broju skrivenih slojeva neuronske mreže kao i ovisnost o broju neurona po skrivenom sloju unutar jedne neuronske mreže.

Što se tiče ovisnosti o broju neurona po skrivenom sloju i ovisnosti o broju skrivenih slojeva, iz navedenih rezultata vidimo da povećanjem broja neurona po skrivenom sloju pridonosimo smanjenju MSE. Isto tako povećanjem broja skrivenih slojeva, dolazi do smanjenja MSE-a.

Glede aktivacijske funkcije, mreža je dobila najbolje rješenje za **relu** aktivacijsku funkciju neurona u skrivenom sloju. Također iz prikazanih rezultata vidimo da je **lbfgs** algoritam za učenje mreže dao najbolje rezultate.